

Friedman-I 本実験結果メモ

warm-up 除外世代定義に基づく bo_current の評価

2026 年 06 月 12 日

1 目的

本メモは、Friedman-I シンボリック回帰問題に対して、現行の提案手法である `bo_current` を適用した本実験結果をまとめるものである。今回から、ユーザー指定の「世代数」は BO の warm-up を含まない本制御・本評価区間の世代数として扱う。したがって、本実験の設定は

$$\text{総世代数} = \text{warm-up 世代数} + \text{本評価世代数} = 18 + 60 = 78$$

である。

2 問題選定の理由

対象問題は Friedman-I 型のシンボリック回帰である。入力変数を $x_1, \dots, x_5$ とすると、目標関数は

$$y = 10 \sin(\pi x_1 x_2) + 20(x_3 - 0.5)^2 + 10x_4 + 5x_5$$

で与えられる。各入力 $x_i \sim U(0, 1)$ から生成し、訓練点数は 200、テスト点数は 200 とした。

Friedman-I を採用した理由は次の通りである。第一に、McDermott らの “Genetic Programming Needs Better Benchmarks” は、GP 研究で単純すぎる toy benchmark のみを用いることの危険性を指摘している。Friedman-I は、線形項、二次項、三角関数、変数間相互作用を含むため、単純な $y = x^2 + x$ 型の smoke test よりも本実験に適している。第二に、White らの “Better GP Benchmarks” は、benchmark 選定と実験厳密性、複数 seed による評価の重要性を述べている。本実験ではこの考えに従い、固定した問題設定のもとで 100 seed を用いる。第三に、La Cava らの SRBench は、symbolic regression を再現可能な benchmark として扱う枠組みを示しており、精度とモデル複雑さの両方を考慮する評価と相性がよい。さらに Liu らの MOGP symbolic regression の研究では、NSGA-II による accuracy-complexity 探索で低複雑度個体が過剰に複製され、探索効率や多様性に影響する現象が報告されている。これは本研究の状態観測量である HV、直近改善量、多様性、平均木サイズ、停滞長を用いた閉ループ制御の意義と対応している。

3 目的関数と評価指標

GP の目的関数は 2 目的である．第 1 目的は訓練データに対する正規化 RMSE，第 2 目的は式木サイズであり，いずれも最小化する．すなわち，個体 T に対して

$$f_1(T) = \text{NRMSE}_{\text{train}}(T), \quad f_2(T) = |T|$$

を考える．本実験では，探索の成果集合である archive に基づく final archive HV を主指標とし，population diversity を副指標として用いる．また，warm-up 後の挙動を評価するため，

$$\Delta \text{HV}_{\text{post}} = \text{HV}_{g=78} - \text{HV}_{g=18}$$

と，warm-up 後の HV 時間平均を用いる．

4 実験条件

比較対象は，固定率 GP 3 条件と，提案法 `bo_current` である．全手法で同じ多目的 GP エンジンを用い，違いは p_c , p_m , 更新周期 k の決定方法のみに限定した．

表 1 比較した制御条件

手法	設定	位置づけ
<code>plain_fixed_standard</code>	$p_c = 0.80, p_m = 0.05$	標準的な固定率 GP
<code>plain_fixed_high_mutation</code>	$p_c = 0.70, p_m = 0.20$	突然変異を強めた固定率 GP
<code>plain_fixed_high_crossover</code>	$p_c = 0.90, p_m = 0.05$	交叉を強めた固定率 GP
<code>bogp_current</code>	p_c, p_m, k を BO で逐次決定	提案法の現行版

表 2 本実験の条件

項目	設定
対象問題	Friedman-I symbolic regression
seed	$0, \dots, 99$
seed 数	100
集団サイズ	24
warm-up 世代数	18
本評価世代数	60
総世代数	78
評価回数	1872 / run
目的数	2
archive key	topology + node value
HV 参照点	(1.0, 1.0)

現行の `bo_current` では、 $k \in \{1, 3, 5\}$ に対して各 k を 2 回ずつ warm-up する。sequential warm-up のため、世代数としては

$$1 + 1 + 3 + 3 + 5 + 5 = 18$$

世代が warm-up 区間に対応する。その後の 60 世代を本制御・本評価区間として扱った。

5 結果

表 3 Friedman-I 本実験の最終指標

手法	HV 平均	HV 標準偏差	多様性平均	多様性標準偏差	warm-up 後 HV 増加	HV-AUC
<code>plain_fixed_standard</code>	0.782991	0.055371	0.624480	0.108696	0.056333	0.765837
<code>plain_fixed_high_mutation</code>	0.808315	0.029862	0.646372	0.082247	0.071250	0.788341
<code>plain_fixed_high_crossover</code>	0.794766	0.029513	0.630678	0.081329	0.054044	0.776636
<code>bogp_current</code>	0.802461	0.022454	0.640513	0.086765	0.062183	0.787353

表 3 より、final archive HV 平均が最も高い手法は `plain_fixed_high_mutation` であった。`bogp_current` は標準固定率 GP に対して、seed 内 final HV 差分平均 0.019469 を示した。一方、高突然変異固定率 GP に対する差分平均は-0.005854 であった。




図 1 final archive HV と final diversity の平均 ± 標準偏差

図 3 に archive HV の推移を示す。破線は warm-up 終了世代 $g = 18$ を表す。この図により、初期区間を含めた収束過程と、warm-up 後の本評価区間でどの手法が Pareto archive を押し上げたかを分けて確認できる。

5.1 seed 内差分

5.2 `bo_current` の制御傾向

`bo_current` の更新周期 k は、単なる選択回数だけでなく、どの世代区間で保持されたかを確認する必要がある。図 7 に、代表 seed=26 における archive HV, population diversity, および保持され




図2 100 seed における final archive HV の分布




図3 archive HV の世代推移. 帯は標準偏差を示す

表4 bo_current と固定率 GP の seed 内 final HV 差分

比較	差分平均	差分標準偏差	win	tie	loss	Wilcoxon p
bo_current - standard	0.019469	0.054009	70	2	28	0.0000
bo_current - high mutation	-0.005854	0.032360	40	1	59	0.0103
bo_current - high crossover	0.007695	0.036345	57	1	42	0.0523
bo_current - best fixed per seed	-0.014851	0.025748	31	0	69	0.0000




図4 population diversity の世代推移. 帯は標準偏差を示す




図5 warm-up 後の HV-AUC と HV 増加量

た更新周期 k の対応を示す. ここで k は, その世代の結果を表す値ではなく, 制御更新時点で選択され, 次の更新時点までの区間に適用された制御入力である. したがって, k の意味は, 同じ世代の HV や多様性ではなく, その後の区間で HV や多様性がどのように変化したかに対応づけて読むべきである.

補助情報として, 全制御ステップにおける k 選択回数は

$$k = 1 : 1702, \quad k = 3 : 816, \quad k = 5 : 730$$

であり, warm-up 後に限定すると

$$k = 1 : 1502, \quad k = 3 : 616, \quad k = 5 : 530$$




図6 bo_current と固定率 GP の seed 内 final HV 差分

であった。warm-up 後の平均操作率は

$$\bar{p}_c = 0.7137, \quad \bar{p}_m = 0.1402$$

であった。

6 考察

本実験では、warm-up を世代数に含めず、BO が初期観測を終えた後の 60 世代を本評価区間として明示した。これにより、従来の 30 世代実験よりも bo_current が状態観測に基づいて制御入力を選ぶ期間を長く確保できた。

結果の解釈では、final archive HV を主指標としつつ、population diversity と warm-up 後の HV 改善量を併せて見る必要がある。Friedman-I は accuracy-complexity の 2 目的問題であるため、単に誤差を下げるだけではなく、低複雑度の式と高精度の式のトレードオフをどれだけ広く獲得できるかが重要である。そのため、archive HV は成果集合の品質を表し、population diversity は探索状態の偏りや早期収束を読む補助指標となる。

また、強い固定率 baseline として高突然変異設定を置いたことにより、提案法の評価は単なる標準固定率 GP との比較に留まらない。bo_current が標準固定率を上回る場合でも、高突然変異固定率や seed ごとの best fixed に対して十分に優位でなければ、「閉ループ制御の枠組みは有望だが、報酬設計や BO 制御器には改善余地がある」と解釈するのが妥当である。

7 参照した文献と反映箇所

- McDermott et al. (2012), “Genetic Programming Needs Better Benchmarks”: toy problem だけに依存せず、説明しやすくも単純すぎない benchmark を選ぶ根拠として参照した。
- White et al. (2013), “Better GP Benchmarks”: 複数 seed, 比較 baseline, 出力ログを揃えた実験設計の根拠として参照した。




図7 代表 seed=26 における archive HV, population diversity, 更新周期 k の世代対応. k は選択後の区間に保持される制御入力である.




図8 代表 seed=26 における最終 Pareto archive

- La Cava et al. (2021), “Contemporary Symbolic Regression Methods and their Relative Performance / SRBench”: symbolic regression を train/test split を持つ benchmark として扱い, accuracy と model complexity を重視する方向性の根拠として参照した.
- Liu et al. (2022), “Evolvability Degeneration in Multi-Objective Genetic Programming for Symbolic Regression”: accuracy–complexity MOGP における低複雑度個体の過剰複製や多様性低下の問題を, 本研究の状態観測と報酬設計の背景として参照した.
- Li and Yao (2019), “Quality evaluation of solution sets in multiobjective optimisation: a survey”: Pareto archive の品質評価において, HV と多様性など複数観点を併用する考え方の根拠として参照した.